Tối ưu vận hành doanh nghiệp bằng mô hình dự báo tích hợp

Lê Bảo Nam Khánh
Trường Đại học Kinh tế - Luật, ĐHQG-HCM
lbnkhanh07102006@gmail.com
Nguyễn Gia Phúc
Trường Đại học Kinh tế - Luật, ĐHQG-HCM
sumoyafood@gmail.com
Nguyễn La Thanh Thảo
Trường Đại học Kinh tế - Luật, ĐHQG-HCM
jessie.thao19@gmail.com
Trương Võ Trường Thy
Trường Đại học Kinh tế - Luật, ĐHQG-HCM
thyvotruong@gmail.com

Tóm tắt nội dung

Báo cáo này trình bày giải pháp tối ưu hóa hiệu suất kinh doanh cho một doanh nghiệp thương mại điện tử quy mô lớn thông qua việc phân tích hệ sinh thái dữ liệu đa chiều. Nhóm nghiên cứu thực hiện quy trình xử lý dữ liệu tích hợp từ 15 nguồn khác nhau, tập trung vào việc giải quyết các điểm nghẽn về logistics, tỷ lệ chuyển đổi thấp và rủi ro hoàn hàng. Chúng tôi đề xuất một pipeline dự báo chuỗi thời gian sử dụng thuật toán XGBoost, tích hợp các đặc trưng về sự kiện thị trường và lưu lượng truy cập web để dự báo chính xác doanh thu và giá vốn hàng bán (COGS). Kết quả thực nghiệm cho thấy mô hình không chỉ đạt độ chính xác cao mà còn cung cấp khả năng giải thích thông qua giá trị SHAP, giúp chuyển hóa các chỉ số kỹ thuật thành các khuyến nghị chiến lược cụ thể. Giải pháp hướng tới việc bảo vệ biên lợi nhuận và nâng cao hiệu quả vận hành dựa trên bằng chứng dữ liệu.

1 Giới thiệu

Trong thị trường thương mại điện tử đầy biến động như hiện nay, việc cân bằng giữa tăng trưởng doanh thu và tối ưu chi phí vận hành là thách thức sống còn của các công ty. Báo cáo này phân tích hệ sinh thái dữ liệu 16 tỷ USD nhằm giải quyết các điểm nghẽn về logistics (giao trễ), marketing (chuyển đổi thấp) và quản trị sản phẩm (hoàn hàng). Thông qua việc hợp nhất đa nguồn dữ liệu và ứng dụng mô hình học máy XGBoost, nhóm đề xuất một hệ thống dự báo tích hợp doanh thu - giá vốn, giúp chuyển hóa dữ liệu thô thành các quyết định chiến lược nhằm tối ưu biên lợi nhuận và nâng cao trải nghiệm khách hàng.

2 Phân tích dữ liệu

Trong phần này, nhóm đã thực hiện phân tích đa chiều dựa trên sự kết hợp của các tập dữ liệu sau khi đã làm sạch để xác định các yếu tố then chốt ảnh hưởng đến hiệu quả kinh doanh.

2.1 Hiệu quả logistics và sự hài lòng của khách hàng

Dựa trên dữ liệu từ shipments.csv, nhóm nhận thấy hiệu suất giao hàng đang gặp vấn đề nghiêm trọng.

- Thực trạng: Thời gian giao hàng trung bình đạt 6.00 ngày, nhưng tỷ lệ giao hàng trễ lên tới 41.64%.

- Chẩn đoán: Tỷ lệ trả hàng do lỗi "Sản phẩm không như mô tả" chiếm 0.98%. Việc chờ đợi quá lâu kết hợp với kỳ vọng sai lệch dẫn đến điểm đánh giá thấp.
- Giải pháp: Tối ưu hóa lộ trình tại các khu vực có tỷ lệ trễ cao (đặc biệt là miền Tây).

2.2 Marketing - chất lượng chuyển đổi theo thiết bị

Kết nối web_traffic.csv và orders.csv, nhóm phát hiện sự đứt gãy trong lưu lượng chuyển đổi.

- Thực trạng: Tỷ lệ chuyển đổi chung cực thấp, chỉ đạt 0.71%.
- Chẩn đoán: Lưu lượng truy cập từ Paid Search cao nhưng Bounce Rate lớn cho thấy quảng cáo nhắm sai đối tượng. Đồng thời, việc lạm dụng khuyến mãi từ promotions.csv đang tạo ra tệp khách hàng thiếu trung thành, chỉ mua khi có deal.

2.3 Quản trị danh mục và rủi ro hoàn hàng

- Thực trạng: Streetwear là danh mục chủ lực đóng góp phần lớn doanh thu trong tổng số $16 tỷ. Tuy nhiên, biên lợi nhuận gộp chỉ ở mức 13.80%.
- Chẩn đoán: Tỷ lệ trả hàng Wrong Size cao đột biến trong khi Rating vẫn ở mức khá (3.8 sao) cho thấy lỗi hệ thống trong bảng hướng dẫn kích cỡ cho khách hàng. Ngoài ra, hiện tượng đồng thời tồn tại stockout_days và overstock_flag chứng tỏ khâu dự báo nhu cầu đang thất bại, gây đọng vốn cục bộ.

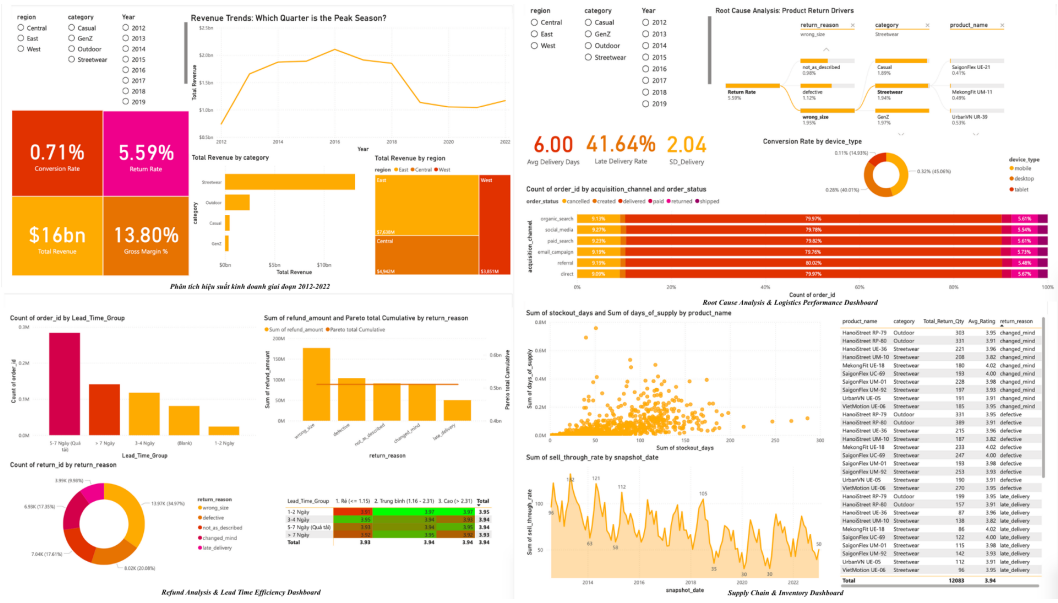

Hình 1: Dashboard phân tích & thống kê các dữ liệu

3 Mô hình Dự báo

Nhóm tiếp cận bài toán dự báo doanh thu và giá vốn hàng bán thông qua ba giai đoạn phát triển mô hình, chuyển từ các đặc trưng thời gian cơ bản sang hệ thống đặc trưng nâng cao.

3.1 Xác định vấn đề

Mục tiêu là dự báo chuỗi thời gian (y_t, c_t), trong đó y_t là doanh thu và c_t là giá vốn hàng bán (COGS) tại thời điểm t. Để xử lý tính biến động cao và phân phối lệch của dữ liệu bán lẻ, nhóm áp dụng phép biến đổi logarit:

$$z_t = \ln(y_t + 1) \tag{1}$$

Từ đây, bài toán trở thành việc học một hàm ánh xạ f:

$$\hat{z}_{t+1} = f(\mathcal{X}_t) \tag{2}$$

với $\mathcal{X}_t$ là tập hợp các đặc trưng được trích xuất tại thời điểm t.

3.2 Baseline model

Mô hình cơ sở sử dụng thuật toán Random Forest Regressor với tập đặc trưng tĩnh dựa trên lịch ($\mathcal{X}_{calendar}$). Các đặc trưng bao gồm: năm, tháng, ngày, thứ trong tuần, quý, và biến giả cuối tuần ($\mathbb{I}_{weekend}$).

COGS Estimation: Trong giai đoạn này, COGS được ước tính bằng một tỷ lệ cố định dựa trên toàn bộ lịch sử dữ liệu huấn luyện:

$$\hat{c}_t = y_t \times \frac{\sum c_{train}}{\sum y_{train}} \tag{3}$$

3.3 Time-series pipeline

Để khắc phục hạn chế của mô hình cơ sở, nhóm xây dựng một pipeline xử lý chuỗi thời gian chuyên biệt:

- Temporal Features: Bổ sung các biến trễ (Lag features): y_{t-1}, y_{t-7} để nắm bắt tính tự tương quan. Các số liệu thống kê lăn (Rolling statistics) như trung bình trượt 7 ngày và 30 ngày được tính toán để làm mịn nhiễu.
- Validation Strategy: Nhóm sử dụng TimeSeriesSplit với 5-fold, đảm bảo mô hình luôn được huấn luyện trên dữ liệu quá khứ và kiểm chứng trên dữ liệu tương lai gần, tránh rò rỉ thông tin.
- Dynamic COGS: Tỷ lệ giá vốn được cập nhật dựa trên cửa sổ 30 ngày gần nhất để thích ứng với biến động chi phí ngắn hạn.

3.4 Advanced model

Mô hình tối ưu nhất chuyển sang thuật toán XGBoost và mở rộng không gian đặc trưng ($\mathcal{X}_{ext}$).

3.4.1 Domestic event engineering

Định nghĩa tập hợp các sự kiện đặc biệt $\mathcal{E}$ có tác động mạnh đến sức mua:

- Double Days: Các ngày siêu sale (9/9, 10/10, 11/11, 12/12).
- Payday Effect: Ngày 5 và ngày cuối tháng.
- Regional Holidays: Các ngày lễ (1/1, 14/2, 8/3, 20/10,...).

3.4.2 Behavioral and volatility signals

Mô hình tích hợp dữ liệu từ lưu lượng web. Các biến sessions và page_views được sử dụng như những chỉ số dẫn dắt. Ngoài ra, độ lệch chuẩn trượt 7 ngày được bổ sung để cung cấp tín hiệu về độ biến động của thị trường.

3.4.3 Optimization and constraints

Mô hình XGBoost được tinh chỉnh với các siêu tham số: learning_rate=0.015 và max_depth=6. Để đảm bảo tính hợp lý kinh tế, nhóm áp dụng ràng buộc cứng:

$$\hat{c}_t = y_t \times \min\left(\frac{\sum_{i=1}^{90} c_{t-i}}{\sum_{i=1}^{90} y_{t-i}}, 1.0\right) \tag{4}$$

3.5 Model explainability

Giá trị SHAP được dùng để định lượng đóng góp của từng đặc trưng. Bằng cách tính toán đóng góp cận biến như Lag_7 hay Is_Payday, mô hình cung cấp các thông tin có thể kiểm chứng với thực tế kinh doanh.

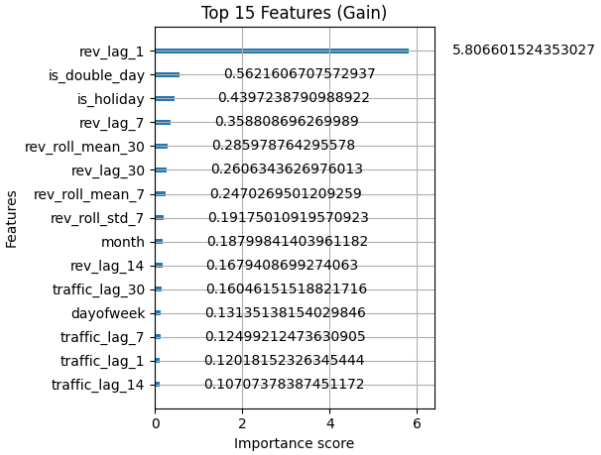

Hình 2: Tầm quan trọng của các đặc trưng dựa trên Gain

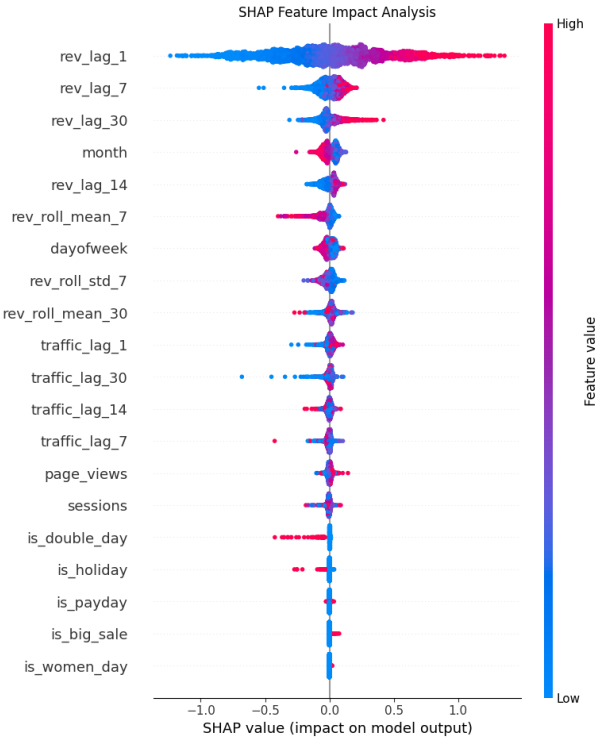

Hình 3: Biểu đồ SHAP Summary thể hiện tác động của các yếu tố thị trường

Mã nguồn

Nhằm đảm bảo tính minh bạch và khả năng tái lập kết quả, nhóm cung cấp toàn bộ mã nguồn tại: github.com/Fook2903/Inbiz